



PROCESSAMENTO DE LINGUAGEM NATURAL

Agenda

- Apresentação da disciplina
- Apresentação do Projeto
- Definição dos Grupos
- Introdução
- Preparação do ambiente

Professora

Maria Janaina da Silva Ferreira.

- Mestra em Ciência da Computação
- MBA em Projetos de Aplicações Digitais
- Especialista em Desenvolvimento de Sistemas
- Graduada em Análise e Desenvolvimento de Sistemas
- Desenvolvedora Full Stack



maria.ferreira21@fatec.sp.gov.br



<http://lattes.cnpq.br/5089569392136404>

Competências Profissionais

- Selecionar e empregar tecnologias de inteligência artificial aplicáveis ao desenvolvimento de aplicações para dispositivos móveis e web.
- Agir com pensamento crítico voltado à resolução de situações-problema.

Objetivo



- Empregar técnicas e teorias de Inteligência Artificial aplicada ao Processamento de Linguagem Natural.
- Conhecer e aplicar técnicas e métodos para construção de recursos, ferramentas e aplicações de PLN.
- Construir mecanismos artificiais que permitam o entendimento de linguagem natural para realizar tarefas ou aplicações.
- Empregar linguagens de programação para o desenvolvimento de soluções.

Ementa

- Processamento de linguagem natural. Aplicações de processamento de linguagem natural. Processamento de texto. Extração de características (features). Análise sintática. Interpretação semântica. Gramáticas. Descoberta de conhecimento em textos (Knowledge Discovery in Texts). Análise de sentimentos. Aprendizagem de máquina aplicada ao processamento de linguagem natural. Reconhecimento de voz.

Carga Horária

- 80 horas
- 4 aulas semanais



Critérios de Avaliação

- 3 avaliações
 - 2 Avaliações teóricas/Prática
 - Projeto Prático - Seminário
 - Atividades em Aula
- Média
 - $(P1 * 0.30) + (P2 * 0.40) + (PJ * 0.30)$



Avaliações

- Avaliações teóricas – P1, P2
 - Conceitual
 - Individual
 - Sem consulta
- Atividades Práticas
 - Prático
 - Em grupos
 - Desenvolvimento em sala e extra classe

Projeto Prático

- 3 entregas
 - Apresentação da implantação de reconhecimento de voz = 40%
 - Apresentação da implantação do chatbot = 40%
 - Apresentação presencial na Fatec = 20%

Bibliografia

- Bibliografia Básica:

- FERREIRA, M., LOPES, M. Para conhecer linguística computacional. São Paulo: Contexto, 2019
- RAJ, S. Construindo Chatbots com Python: Usando Natural Language Processing e Machine Learning. São Paulo: Novatec, 2019.
- RUSSEL, M.A. Mineração de Dados da Web Social: Análise de dados do Facebook, Twitter, LinkedIn e outros sites de mídia social. São Paulo: Novatec, 2019.

- Bibliografia Complementar:


- GÉRON, A. Mãos à Obra: Aprendizado de Máquina com Scikit-Learn & TensorFlow. Rio de Janeiro: Alta Books, 2019.
- HOBSON, L., COLE, H., HANNES, H. Natural Language Processing in Action: Understanding, analyzing, and generating text with Python. Manning, 2019.
- MCKINNEY, W. Python Para Análise de Dados: Tratamento de Dados com Pandas, NumPy e IPython. São Paulo: Novatec, 2018.
- MUELLER, J. P., MASSARON, L. Python Para Data Science Para Leigos. Rio de Janeiro: Alta Books, 2020.
- TAKAHASHI, S., INOUE, I. Guia Mangá de Análise de Regressão. São Paulo: Novatec, 2019.
- TAKAHASHI, S., INOUE, I. Guia Mangá de Estatística. São Paulo: Novatec, 2010. 60
- VAJJATA, S., MAJUMDER, B., GUPTA, A., SURANA, H. Practical Natural Language Processing: A Comprehensive Guide to Building Real-World NLP Systems. O'Reilly Media, 2020.

Formação dos Grupos

- O representante do grupo deverá enviar no chat:
 - Nome do grupo
 - Nome do projeto
 - Nome dos integrantes

10 Minutos

Introdução



Língua - Sistema e Regras

Linguagem - Comunicação e Expressão

O que é PLN

- Área da Inteligência Artificial que lida com a interação entre linguagem humana e computadores.
- Objetivo: permitir que máquinas compreendam, interpretem e gerem linguagem natural.

O que é PLN

Processamento de Linguagem Natural (PLN) é um subcampo da Inteligência Artificial (IA) e da Linguística Computacional que estuda e desenvolve métodos computacionais para o processamento, análise e geração da linguagem humana em forma textual ou falada. O objetivo do PLN é permitir que máquinas compreendam, interpretem, manipulem e produzam linguagem natural de maneira significativa e eficiente.

Principais componentes do PLN

- **Análise léxica:** identificação de palavras e morfemas.
- **Tokenização e segmentação:** separação de texto em unidades menores.
- **Análise sintática:** estrutura gramatical e relações entre palavras.
- **Análise semântica:** interpretação de significado.
- **Análise pragmática:** entendimento do contexto e da intenção.
- **Geração de linguagem natural:** produção automatizada de texto.

Aplicações

- Assistentes virtuais (Siri, Alexa)
- Tradução automática (Google Translate)
- Correção ortográfica e gramatical
- Chatbots e atendimento automatizado
- Análise de sentimentos
- Extração de informações (NER)

Histórico do PLN

- Décadas de 1950-60: primeiras tentativas com gramáticas formais.
- Anos 1980: evolução com modelos estatísticos.
- 2000+: explosão com aprendizado de máquina e deep learning.
- Hoje: integração com grandes modelos de linguagem (LLMs).

Desafios dos PLN

- Ambiguidade lexical e sintática
- Ironia e sarcasmo
- Contexto e pragmática
- Multilinguismo e regionalismos

Ferramentas para Trabalhar com PLN

- Linguagens:
 - Python
- Bibliotecas:
 - NLTK
 - spaCy
 - Scikit-learn
 - Transformers (HuggingFace)
 - Gensim

Preparação do Ambiente

- Recomendado: Google Colab (baseado na nuvem, gratuito)
- Alternativas: Jupyter Notebook + Anaconda (local)

Bibliotecas - Python

- NLTK
 - Funcionalidades para manipulação de strings
 - Interfaces padrões para realizar tarefas como etiquetar textos, frequência de palavras, lematização e stemmização de palavras, entre vários outros.
- Disponível em: <http://www.nltk.org/index.html>

Bibliotecas - Python

- Dentro do NLTK contém vários corpú, que são úteis para os etiquetadores, entidades nomeadas, estruturas sintáticas e várias outras funcionalidades.
- Alguns corpus:

Corpus	Compiler	Contents
Brown Corpus	Francis, Kucera	15 genres, 1.15M words, tagged, categorized
CESS Treebanks	CLiC-UB	1M words, tagged and parsed (Catalan, Spanish)
Chat-80 Data Files	Pereira & Warren	World Geographic Database
CMU Pronouncing Dictionary	CMU	127k entries
CoNLL 2000 Chunking Data	CoNLL	270k words, tagged and chunked
CoNLL 2002 Named Entity	CoNLL	700k words, pos- and named-entity-tagged (Dutch, Spanish)
CoNLL 2007 Dependency Treebanks (sel)	CoNLL	150k words, dependency parsed (Basque, Catalan)
Dependency Treebank	Narad	Dependency parsed version of Penn Treebank sample
FrameNet	Fillmore, Baker et al	10k word senses, 170k manually annotated sentences
Floresta Treebank	Diana Santos et al	9k sentences, tagged and parsed (Portuguese)
Gazetteer Lists	Various	Lists of cities and countries
Genesis Corpus	Misc web sources	6 texts, 200k words, 6 languages
Gutenberg (selections)	Hart, Newby, et al	18 texts, 2M words
Inaugural Address Corpus	Cspan	US Presidential Inaugural Addresses (1789-present)
Indian POS-Tagged Corpus	Kumaran et al	60k words, tagged (Bangla, Hindi, Marathi, Telugu)
MacMorpho Corpus	NILC, USP, Brazil	1M words, tagged (Brazilian Portuguese)
Movie Reviews	Pang, Lee	2k movie reviews with sentiment polarity classification
Names Corpus	Kantrowitz, Ross	8k male and female names
NIST 1999 Info Extr (selections)	Garofolo	63k words, newswire and named-entity SGML markup
Nombank	Meyers	115k propositions, 1400 noun frames
NPS Chat Corpus	Forsyth, Martell	10k IM chat posts, POS-tagged and dialogue-act tagged
Open Multilingual WordNet	Bond et al	15 languages, aligned to English WordNet
PP Attachment Corpus	Ratnaparkhi	28k prepositional phrases, tagged as noun or verb modifiers
Proposition Bank	Palmer	113k propositions, 3300 verb frames

- Cap. 1.6 - <https://www.nltk.org/book/ch02.html>

Bibliotecas - Python

- Algumas funções importantes no tratamento de textos com NLTK.
 - Tokenização: separa o texto em palavras e símbolos.
 - Frequência/Contagem de palavras: contagem de ocorrência de tokens
 - Stopwords: são palavras que podem ser consideradas irrelevantes
 - N-gramas: sequências contíguas de n itens de uma amostra
 - Stemmer: reduzir a palavra ao seu radical
 - Lemma: reduz palavras às suas formas básicas (ex.: "correram" → "correr").
 - Etiquetadores: catalogar as palavras de acordo com a classe

Bibliotecas - Python

- Spacy
 - Biblioteca open-source voltada para processamento de linguagem natural.
 - Focada em desempenho e produção, sendo usada em aplicações reais de PLN.
 - Oferece modelos pré-treinados para diversos idiomas, incluindo Português.

Bibliotecas - Python

- Principais funcionalidades
 - Tokenização
 - Lematização
 - Análise sintática (parser): identifica relações gramaticais entre palavras.
 - Reconhecimento de entidades nomeadas (NER): detecta nomes de pessoas, lugares, organizações etc.
 - Classificação de texto: permite treinar modelos para categorizar documentos.
 - Segmentação de sentenças: divide textos em frases.
 - Suporte a pipelines customizadas: fácil integração com outras ferramentas de IA.

Bibliotecas - Python

- Modelo em português
 - Modelo principal: pt_core_news_sm (leve, otimizado para CPU).
 - Componentes: tok2vec, morphologizer, parser, lemmatizer, senter, ner, attribute_ruler.
- Disponível em: <https://spacy.io/>

Criando um projeto no Colab

- Acesse: <https://colab.research.google.com/>
- Clique em "Novo notebook"
- Configuração automática do ambiente Python

Instalação de Bibliotecas (NLTK e spaCy)

- No novo notebook criado, clique em uma célula e digite o comando abaixo. Pressione **shift+enter** para executar ou pressione o botão play

```
!pip install nltk
```

```
!pip install spacy
```

- Também é possível instalar pacotes adicionais para Tokenização

```
import nltk
```

```
nltk.download('punkt') # Para tokenização
```